Simulação de Dinâmicas de Sala de Aula via Ecossistemas Multiagente: um Mapeamento Sistemático sobre Arquiteturas, Personas e Formação Docente

Autoria omitida para revisão

Instituição omitida para revisão

omitido@omitido

Abstract. *Large language models (LLMs) now support simulated classrooms in which several agents act as teacher, students and peers. This systematic mapping study examines multi-agent ecosystems that simulate classroom dynamics and collaborative learning, asking which coordination architectures and persona models are used and what is known about their effect on teachers' pedagogical decisions. Fifteen primary studies (2023–2026) were classified by coordination pattern, persona mechanism and validation strategy. Centralized orchestration predominates, seven studies define personas through prompting alone, and none of the eight teacher-training studies measures transfer to real classrooms. No study addresses Portuguese or the Brazilian curriculum.*

Resumo. *Modelos de linguagem de grande escala (LLMs) viabilizaram turmas simuladas em que vários agentes atuam como professor, alunos e colegas. Este mapeamento sistemático examina ecossistemas multiagente que simulam dinâmicas de sala de aula e aprendizagem colaborativa, investigando quais arquiteturas de coordenação e modelos de persona são usados e o que se sabe sobre seu efeito na decisão pedagógica de educadores. Quinze estudos primários (2023–2026) foram classificados por padrão de coordenação, mecanismo de persona e estratégia de validação. Predomina a orquestração centralizada, sete estudos definem personas apenas por prompt e nenhum dos oito estudos de formação docente mede transferência para a sala real. Não há estudos em português nem alinhados à BNCC.*

1. Introdução

A formação de professores depende de oportunidades de prática em que o licenciando possa errar, receber retorno e tentar de novo. No estágio supervisionado essas oportunidades são escassas e pouco controláveis: não se escolhe quando surgirá um equívoco conceitual persistente ou uma discussão dominada por um único estudante. Simulações de ensino tentam suprir essa lacuna, mas as soluções de realidade mista mais difundidas dependem de atores humanos que operam os avatares dos alunos, o que encarece o treino e limita sua escala.

Os modelos de linguagem de grande escala (LLMs) mudaram esse cenário. Agentes generativos com memória, planejamento e reflexão produzem comportamento social verossímil [Park et al. 2023], e arcabouços multiagente passaram a coordenar vários desses agentes em uma mesma tarefa [Guo et al. 2024]. Na educação, surgiram duas linhas quase paralelas: turmas multiagente voltadas ao aprendiz, em que professor, monitores e

colegas virtuais interagem com o estudante [Zhang et al. 2025, Yu et al. 2025], e alunos simulados para que professores e tutores pratiquem [Markel et al. 2023, Pan et al. 2025]. Ao mesmo tempo, cresce a crítica à fidelidade desses alunos, num paradoxo em que um modelo amplamente capaz é instruído a agir como aprendiz que sabe pouco [Yuan et al. 2026]. Essa literatura cresce de forma fragmentada: cada sistema define o próprio controlador de turma, as personas raramente são relacionadas à forma como foram validadas, e os estudos de formação docente medem sobretudo percepção.

Este artigo apresenta um mapeamento sistemático sobre ecossistemas multiagente que simulam dinâmicas de sala de aula e aprendizagem colaborativa, orientado por duas questões:

- **RQ1**: Quais arquiteturas de orquestração multiagente e personas são utilizadas para simular perfis cognitivos e comportamentais heterogêneos em sala de aula?
- **RQ2**: De que maneira o treinamento imersivo com turmas simuladas por agentes impacta a tomada de decisão pedagógica de educadores?

As contribuições são: (i) uma taxonomia de coordenação descrita com o vocabulário da engenharia de software; (ii) um esquema de classificação de personas cruzado com o tipo de validação; e (iii) um mapa da evidência sobre decisão pedagógica, com uma agenda de pesquisa para o Brasil.

2. Trabalhos Relacionados

Quatro estudos secundários delimitam o terreno deste mapeamento. Käser e Alexandron [2024] revisam a pesquisa sobre aprendizes simulados, em boa parte anterior aos LLMs, e propõem um teste do tipo Turing para julgá-los. Marquez-Carpintero et al. [2025] revisam arquiteturas e mecanismos de simulação de estudantes com IA generativa, inclusive em cenários multiagente, e apontam a fragilidade da validação. Yuan et al. [2026] tratam a simulação como geração restrita por uma especificação explícita do estado epistêmico do aprendiz e organizam a área por objetivos pedagógicos. Aperstein et al. [2025] revisam plataformas de IA generativa para a prática deliberada de ensino.

Esses trabalhos tomam o aluno simulado como unidade de análise, e não a coordenação entre agentes. Nenhum compara como o turno de fala é decidido e onde o estado da turma é mantido, nenhum cruza mecanismo de persona e validação, e nenhum separa, na formação docente, a percepção dos participantes da qualidade de suas decisões. Os levantamentos sobre sistemas multiagente com LLMs [Guo et al. 2024] oferecem vocabulário para a primeira análise, mas sem foco educacional.

3. Metodologia

O estudo seguiu as diretrizes de mapeamento sistemático de Petersen et al. [2015], e o relato da seleção segue o fluxo PRISMA 2020 [Page et al. 2021]. As subquestões que guiaram a extração cobrem coordenação, turno e estado (RQ1.1); persona e fidelidade (RQ1.2); construtos medidos nos educadores (RQ2.1); e instrumentos, delineamentos e amostras (RQ2.2).

3.1. Fontes, busca e seleção

As buscas foram feitas em Scopus, IEEE Xplore, ACM Digital Library, arXiv e SBC OpenLib (SOL), esta incluída para capturar a produção brasileira, com a *string* abaixo

aplicada a título, resumo e palavras-chave (na SOL, em versão traduzida). A busca foi executada em julho de 2026 e limitada a 2022–2026.

> (“multi-agent” OR “multiagent” OR “generative agent*” OR “simulated student*” OR “simulated learner*” OR “virtual student*” OR “student simulation”) AND (“large language model*” OR LLM* OR GPT* OR “generative AI”) AND (classroom* OR “teacher training” OR “teacher education” OR “pre-service teacher*” OR “tutor training” OR “collaborative learning” OR “peer learning”)

Um estudo é incluído se atende a todos os critérios de inclusão (CI) e a nenhum de exclusão (CE) da Tabela 1. A triagem ocorreu em duas fases, (a) título, resumo e palavras-chave e (b) leitura completa, e, na dúvida, o estudo seguia para a fase (b). Dois revisores aplicaram os critérios de forma independente a cerca de 20% dos registros (Kappa de Cohen de 0,78, concordância substancial [Landis e Koch 1977]), com divergências resolvidas por consenso. A segunda parte do CI1 admite estudos com um único aluno simulado voltados à formação docente, para garantir evidências para a RQ2. Aplicou-se ainda *snowballing* para trás e para frente [Wohlin 2014] a partir dos estudos secundários e dos incluídos.

Tabela 1. Critérios de inclusão e exclusão (versão resumida)

Inclusão		**Exclusão**	
CI1	2+ agentes com papéis pedagógicos distintos, ou aluno simulado para formação docente	CE1	Agente único, sem simulação de aluno ou grupo
CI2	Simula sala de aula, tutoria em grupo ou pares	CE2	LLM apenas como ferramenta (gerar, corrigir)
CI3	Agentes guiados por LLM ou IA conversacional	CE3	Simulação fora do domínio educacional
CI4	Trata de coordenação/personas (RQ1) ou efeitos em educadores (RQ2)	CE4	Alunos roteirizados ou operados por humanos
CI5	Propõe, implementa ou avalia um sistema	CE5	Estudo secundário (só *snowballing*)
CI6	Publicado entre 2022 e 2026	CE6	Pôster, resumo ou tese sem artigo derivado
CI7	Em inglês ou português	CE7	Duplicata (fica a versão mais completa)
CI8	Revisado por pares ou preprint completo	CE8	Texto completo inacessível

3.2. Esquema de classificação

Além de metadados (ano, veículo, país, idioma, público-alvo e número de alunos simulados), três facetas foram definidas *a priori* e refinadas por *keywording* [Petersen et al. 2015]:

- **Coordenação**: **OC**, orquestração central, em que um controlador ou LLM-juiz decide quem fala e quando, como na orquestração de serviços [Peltz 2003]; **EC**, estado compartilhado, em que os agentes agem sobre observações de um estado global, à maneira de um quadro-negro [Nii 1986]; **HI**, hierárquica, em que uma camada superior ajusta as políticas dos agentes; **PL**, *pipeline* de agentes especializados que produz a fala de uma persona; **ND**, não descrita.
- **Persona**: **PR**, apenas prompt; **CO**, modelo explícito de conhecimento ou memória; **AF**, estado afetivo ou traços motivacionais; **MI**, *misconceptions* explícitas; **AJ**, ajuste fino ou otimização de preferências com dados reais.

- **Validação**: **SI**, simulação interna; **FI**, fidelidade aferida sistematicamente (dados reais ou julgamento às cegas); **AP**, aprendizagem ou engajamento de aprendizes; **PE**, percepção ou usabilidade relatada por educadores; **CP**, comportamento pedagógico registrado na simulação; **TR**, transferência para a prática real.

4. Resultados

4.1. Visão geral

A Figura 1 resume a seleção. Na leitura completa, a maioria das exclusões decorreu de LLMs usados apenas como ferramenta (CE2) ou de *chatbots* tutores 1:1 (CE1). Do mapeamento exploratório, foram excluídas uma dissertação sem artigo derivado (CE6) e os trabalhos de Apartsin et al. [2026] e Wu et al. [2025], que simulam respostas de alunos sem dinâmica de interação (CI2) e são retomados na Seção 4.3.

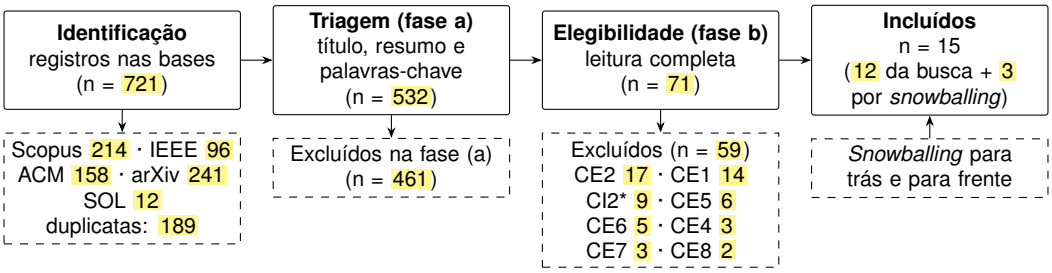


Figura 1. Fluxo de seleção, adaptado de PRISMA 2020 (*CI2 não atendido)

O corpus tem 15 estudos: dois de 2023, dois de 2024, oito de 2025 e três de 2026. Onze passaram por revisão por pares e quatro existem apenas como preprint. Pela afiliação do primeiro autor, vêm da China (6), dos EUA (5), da Coreia do Sul (2), da Índia (1) e da Suíça (1). Todos estão em inglês, e nenhum envolve instituições, estudantes ou currículos brasileiros. A Tabela 2 traz a classificação de cada estudo.

Tabela 2. Classificação dos estudos (Alvo: Apr = aprendizes; Doc = formação docente; Pes = pesquisa; Ava = avaliação de agentes)

Estudo	Alvo	Alunos	Coord.	Persona	Validação	RQ
SimClass [Zhang et al. 2025]	Apr	≥2	OC	PR	AP	1
MAIC [Yu et al. 2025]	Apr	≥2	OC	PR	AP	1
MathVC [Yue et al. 2024]	Apr	≥2	OC	CO, MI	SI, AP	1
OnlineMate [Gao et al. 2025]	Apr	≥2	OC	PR	SI, AP	1
AgentSchool [Ye et al. 2026]	Pes	≥2	EC	CO, AF, MI	SI	1
Sanyal et al. [2025]	Pes	≥2	HI	CO	SI	1
TeachTune [Jin et al. 2025]	Ava	1	PL	CO, AF	FI, PE	1
GPTeach [Markel et al. 2023]	Doc	≥2	OC	PR	PE	2
EducaSim [Mohne et al. 2026]	Doc	≥2	OC	CO	PE, CP	2
TutorUp [Pan et al. 2025]	Doc	≥2	OC	AF	PE, CP	2
Zheng et al. [2025]	Doc	≥2	ND	PR	PE	2
GAD-TT [Lee et al. 2023]	Doc	≥2	ND	PR	PE	2
Evelyn AI [Bhowmik et al. 2024]	Doc	1	PL	AF	FI	2
Cao et al. [2026]	Doc	1	PL	AJ	FI, PE, CP	1, 2
Martynova et al. [2025]	Doc	1	ND	PR	PE	1, 2

4.2. RQ1: arquiteturas de coordenação

A orquestração central domina (7 de 15). Em SimClass e MAIC, um mecanismo de controle de sessão decide qual agente intervém a cada turno, conforme a etapa da aula e os papéis da turma [Zhang et al. 2025, Yu et al. 2025]. EducaSim conduz sessões em pequeno grupo com uma árvore de dinâmica de sala de aula em que um LLM atua como juiz [Mohne et al. 2026]; em MathVC, um controlador de metaplanejamento acompanha as etapas da resolução colaborativa e prevê quem fala em seguida [Yue et al. 2024]; em TutorUp, um agente *BigPicture* escreve a "história" da sessão e escolhe o próximo personagem [Pan et al. 2025]. O padrão concentra a política pedagógica e facilita impor regras de turno, ao custo do acoplamento: o controlador precisa conhecer todos os papéis e tende a virar gargalo quando a turma cresce.

O estado compartilhado aparece apenas em AgentSchool, que modela a escola como processo de transição de estados parcialmente observável: cada agente age sobre observações locais de um estado global (memórias, grafos de conhecimento, grafo social), e a comunicação combina três primitivas, um-para-um, difusão e conversa em grupo [Ye et al. 2026]. É a arquitetura mais próxima de um quadro-negro e a única que persiste o estado da turma fora do histórico de conversa, com até 30 agentes em interação. A coordenação hierárquica aparece em Sanyal et al. [2025]: num laço externo, um algoritmo genético evolui uma população de 500 agentes professores a partir do desempenho de alunos simulados que combinam seis estilos de aprendizagem e cinco tipos de personalidade. O *pipeline* não coordena uma turma, e sim a fala de uma persona: uma cadeia respondedor–avaliador–refinador em Cao et al. [2026], o pipeline *Personalized Reflect-Respond* em TeachTune [Jin et al. 2025] e um módulo de análise de sentimento das falas do licenciando em Evelyn AI [Bhowmik et al. 2024].

Três estudos, todos de formação docente, não descrevem a coordenação em nível suficiente para classificação [Zheng et al. 2025, Lee et al. 2023, Martynova et al. 2025]. Exceto nas cenas informais de AgentSchool, em que os agentes decidem por conta própria entrar ou sair de conversas, o turno é decidido por um componente central ou embutido no roteiro. Nenhum estudo compara padrões de coordenação, e o custo de execução é relatado sem métrica comum, o que limita a replicação.

4.3. RQ1: modelagem de personas

Sete dos 15 estudos definem personas apenas por prompt, em geral por descrições de papel ou traço, como o "palhaço da turma" e o "pensador profundo" de SimClass [Zhang et al. 2025]. Os demais acrescentam mecanismos ao prompt (Figura 2): modelos explícitos de conhecimento ou memória (5 estudos), dos componentes de conhecimento configuráveis de TeachTune e da recuperação de conteúdo por estilo de aprendizagem de Sanyal et al. [2025] aos grafos de conhecimento ponderados de AgentSchool; estados afetivos ou traços motivacionais (4), como autoeficácia e motivação em TeachTune; *misconceptions* explícitas (2), como objetos persistentes em AgentSchool e como erros injetados, a partir de equívocos indicados por professores, nos esquemas de persona de MathVC; e ajuste fino com dados reais e otimização direta de preferências (DPO), só em Cao et al. [2026].

O cruzamento com a validação é revelador: nenhum dos sete estudos com persona apenas por prompt afere sistematicamente a fidelidade do aluno simulado, apoiando-se



Figura 2. Público-alvo dos estudos em relação ao padrão de coordenação (esquerda) e ao mecanismo de persona (direita); a área da bolha acompanha o número de estudos.

em percepção, métricas internas ou ganhos de aprendizes. A aferição só aparece quando a persona vai além do prompt. Em TeachTune, professores tentaram identificar às cegas a configuração de nove alunos simulados; em Cao et al. [2026], ajuste fino, multiagente e DPO superaram o prompt com poucos exemplos em autenticidade cognitiva e linguística. As críticas convergem: professores apontam atenção constante, linguagem complexa, falta de emoções e inconsistência lógica [Martynova et al. 2025], e licenciandos relatam que falhas nos padrões cognitivos simulados prejudicam a suspensão de descrença [Zheng et al. 2025]. Estudos excluídos reforçam o quadro: o controle do domínio parcial por prompt depende do modelo [Apartsin et al. 2026], e o prompt sozinho gera respostas mais avançadas e menos realistas que as de alunos reais [Wu et al. 2025, Scarlatos et al. 2026].

4.4. RQ2: efeitos na tomada de decisão pedagógica

Oito estudos avaliam sistemas com educadores ou licenciandos, e sete deles medem sobretudo a percepção de utilidade, verossimilhança e usabilidade. Apenas três registram comportamento pedagógico na simulação: Cao et al. [2026] analisaram interações de 15 licenciandos com o aluno simulado; em TutorUp, a análise das transcrições de 16 tutores iniciantes sugere melhor aquisição e aplicação de estratégias de engajamento [Pan et al. 2025]; e EducaSim relata dados de uso de sua implantação com 150 dos 1.300 professores voluntários de um curso introdutório de programação com 20 mil alunos [Mohne et al. 2026]. Nenhum estudo mede transferência para a sala real por observação ou delineamento comparativo; o mais próximo é a transferência percebida, autodeclarada, no estudo de caso de Zheng et al. [2025], com 12 licenciandos.

As amostras são pequenas: três professores [Lee et al. 2023], 12 licenciandos [Zheng et al. 2025], oito entrevistados [Cao et al. 2026] e 16 tutores [Pan et al. 2025]; as implantações em escala de GPTeach, com mais de 800 professores iniciantes, e de EducaSim relatam uso e percepção. Só dois estudos têm condição de comparação, e em ambos ela é uma ferramenta sem simulação: um teste A/B em GPTeach [Markel et al. 2023] e um estudo intrassujeitos em TutorUp, em que os tutores julgaram o sistema mais eficaz e usável. Nenhum compara a prática simulada à prática com turmas reais ou com atores humanos, nem acompanha a decisão ao longo do tempo. Além disso, cinco dos oito estudos de formação docente usam mais de um aluno simulado, mas sempre em pequenos grupos ou monitorias, enquanto as simulações mais ricas em estado e em agentes (AgentSchool) e as turmas voltadas ao aprendiz (SimClass, MAIC) não foram usadas para treinar docentes. Não há evidência direta sobre como praticar com uma turma inteira simulada altera a decisão pedagógica.

5. Discussão

5.1. Implicações para o projeto de turmas simuladas

Do ponto de vista da engenharia de software, os resultados sugerem separar três responsabilidades que hoje se misturam no prompt: a política de turno, o estado de cada persona (conhecimento, afeto, equívocos) e o estado da turma (histórico, relações, tarefa). A orquestração central convém quando a política pedagógica precisa ser explícita e auditável; um estado compartilhado do tipo quadro-negro favorece a consistência e a escala, pois o estado deixa de depender da janela de contexto. Relatar padrão de coordenação, política de turno, local do estado, modelo de base, número de agentes e custo por sessão tornaria os sistemas comparáveis, e personas definidas por prompt deveriam passar por algum teste de fidelidade, como o julgamento às cegas de TeachTune ou uma especificação explícita do estado epistêmico [Yuan et al. 2026]. Para a RQ2, o passo seguinte é trocar a variável dependente: em vez de perguntar se o licenciando aprovou a simulação, medir a qualidade de suas decisões em tarefas padronizadas, como vinhetas avaliadas por rubrica, e acompanhar o efeito no estágio.

5.2. Agenda de pesquisa para o contexto brasileiro

Nenhum estudo do corpus foi escrito em português, conduzido no Brasil ou alinhado à BNCC [Brasil 2018], e a fidelidade de uma persona depende da linguagem e dos equívocos típicos de alunos reais. As competências e habilidades da BNCC oferecem um esquema pronto para especificar o domínio parcial de cada aluno simulado, de modo análogo aos vetores de habilidade de Apartsin et al. [2026], e programas como o PIBID e a Residência Pedagógica poderiam abrigar estudos com grupos de comparação. Propõe-se: (i) bases de interações reais em português, anonimizadas conforme a LGPD (Lei 13.709/2018), para calibrar personas; (ii) personas com *misconceptions* documentadas pela pesquisa brasileira em ensino de matemática e ciências; (iii) turmas simuladas com estado compartilhado para treinar gestão de sala e mediação de discussões; e (iv) delineamentos que meçam decisão e transferência.

5.3. Ameaças à validade

A terminologia é instável (*simulated student*, *generative agent*, *role play*), e estudos com termos ausentes da *string* podem ter escapado, risco atenuado pelo *snowballing*. Incluir preprints amplia a cobertura numa área de crescimento rápido, mas traz trabalhos sem revisão por pares, e 2026 está incompleto. A classificação é interpretativa quando a arquitetura é descrita de forma sumária, e o Kappa cobre apenas a seleção. Com 15 estudos, as contagens são descritivas.

6. Conclusão

Quanto à RQ1, a orquestração central predomina, o estado compartilhado aparece em um único sistema e quase metade das personas é definida apenas por prompt, sem aferição sistemática de fidelidade. Quanto à RQ2, a evidência sobre a decisão pedagógica é indireta: mede-se sobretudo percepção, em amostras pequenas, e nenhum estudo acompanha a transferência para a sala real. As duas linhas de trabalho, turmas multiagente para aprendizes e alunos simulados para docentes, ainda não se encontraram. Como trabalho futuro, pretende-se construir uma turma simulada em português, com personas referenciadas à BNCC, para testar seu efeito sobre as decisões de licenciandos.

Referências

Apartsin, A., Sason, O., e Aperstein, Y. (2026). Toward a benchmark for controllable simulation of imperfect students with large language models. arXiv:2605.25601.

Aperstein, Y., Cohen, Y., e Apartsin, A. (2025). Generative AI-based platform for deliberate teaching practice: A review and a suggested framework. *Education Sciences*, 15(4):405.

Bhowmik, S., West, L., Barrett, A., Zhang, N., Dai, C.-P., Sokolikj, Z., Southerland, S., Yuan, X., e Ke, F. (2024). Evaluation of an LLM-powered student agent for teacher training. In *Proc. of EC-TEL 2024*, volume 15160 of *LNCS*, pages 68–74. Springer.

Brasil (2018). *Base Nacional Comum Curricular*. Ministério da Educação, Brasília.

Cao, J., Nguyen, H., Yavuz, S., Yu, B., Wang, S., Bharaj, P. K., e Cross Francis, D. (2026). Developing authentic simulated learners for mathematics teacher learning: Insights from three approaches with large language models. In *Proc. of AIED 2026*. Aceito para publicação. Preprint arXiv:2604.04361.

Gao, X., Zhang, Z., Liu, T., e Fu, Y. (2025). OnlineMate: An LLM-based multi-agent companion system for cognitive support in online learning. arXiv:2509.14803.

Guo, T., Chen, X., Wang, Y., Chang, R., Pei, S., Chawla, N. V., Wiest, O., e Zhang, X. (2024). Large language model based multi-agents: A survey of progress and challenges. In *Proc. of IJCAI 2024*, pages 8048–8057.

Jin, H., Yoo, M., Park, J., Lee, Y., Wang, X., e Kim, J. (2025). TeachTune: Reviewing pedagogical agents against diverse student profiles with simulated students. In *Proc. of CHI 2025*.

Käser, T. e Alexandron, G. (2024). Simulated learners in educational technology: A systematic literature review and a Turing-like test. *International Journal of Artificial Intelligence in Education*, 34.

Landis, J. R. e Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174.

Lee, U. et al. (2023). Generative agent for teacher training: Designing educational problem-solving simulations with large language model-based agents for pre-service teachers. In *NeurIPS 2023 Workshop on Generative AI for Education*.

Markel, J. M., Opferman, S. G., Landay, J. A., e Piech, C. (2023). GPTeach: Interactive TA training with GPT-based students. In *Proc. of ACM Learning@Scale 2023*.

Marquez-Carpintero, L., Lopez-Sellers, A., e Cazorla, M. (2025). Simulating students with large language models: A review of architecture, mechanisms, and role modelling in education with generative AI. arXiv:2511.06078.

Martynova, D., Macina, J., Daheim, N., Yalcin, N., Zhang, X., e Sachan, M. (2025). Can LLMs effectively simulate human learners? Teachers' insights from tutoring LLM students. In *Proc. of the 20th Workshop on Innovative Use of NLP for Building Educational Applications (BEA)*.

Mohne, C., Vo, N., et al. (2026). EducaSim: Interactive simulacra for CS1 instructional practice. arXiv:2603.11444.

Nii, H. P. (1986). The blackboard model of problem solving and the evolution of blackboard architectures. *AI Magazine*, 7(2):38–53.

Page, M. J. et al. (2021). The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ*, 372:n71.

Pan, S., Schmucker, R., Garcia Bulle Bueno, B., Aguilar Llanes, S., Albo Alarcón, F., Zhu, H., Teo, A., e Xia, M. (2025). TutorUp: What if your students were simulated? Training tutors to address engagement challenges in online learning. In *Proc. of CHI 2025*, pages 1–18.

Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., e Bernstein, M. S. (2023). Generative agents: Interactive simulacra of human behavior. In *Proc. of ACM UIST 2023*, pages 1–22.

Peltz, C. (2003). Web services orchestration and choreography. *Computer*, 36(10):46–52.

Petersen, K., Vakkalanka, S., e Kuzniarz, L. (2015). Guidelines for conducting systematic mapping studies in software engineering: An update. *Information and Software Technology*, 64:1–18.

Sanyal, D., Maiti, A., Maharana, U., Kumar, D., Mali, A., Giles, C. L., e Mandal, M. (2025). Investigating pedagogical teacher and student LLM agents: Genetic adaptation meets retrieval-augmented generation across learning styles. In *Proc. of EMNLP 2025*.

Scarlatos, A., Lee, J., Woodhead, S., e Lan, A. (2026). Simulated students in tutoring dialogues: Substance or illusion? In *Proc. of ACL 2026*.

Wohlin, C. (2014). Guidelines for snowballing in systematic literature studies and a replication in software engineering. In *Proc. of EASE 2014*.

Wu, T., Chen, J., Lin, W., Li, M., Zhu, Y., Li, A., Kuang, K., e Wu, F. (2025). Embracing imperfection: Simulating students with diverse cognitive levels using LLM-based agents. In *Proc. of ACL 2025*.

Ye, Y., Li, W., Wen, Z., et al. (2026). AgentSchool: An LLM-powered multi-agent simulation for education. arXiv:2605.30144.

Yu, J., Zhang, Z., Zhang-Li, D., et al. (2025). From MOOC to MAIC: Reimagine online teaching and learning through LLM-driven agents. *Journal of Computer Science and Technology*. DOI 10.1007/s11390-025-6000-0.

Yuan, Z., Xiao, Y., Li, M., Xuan, W., Tong, R., Diab, M., e Mitchell, T. (2026). Towards valid student simulation with large language models. arXiv:2601.05473.

Yue, M., Lyu, W., Mifdal, W., Suh, J., Zhang, Y., e Yao, Z. (2024). MathVC: An LLM-simulated multi-character virtual classroom for mathematics education. arXiv:2404.06711.

Zhang, Z., Zhang-Li, D., Yu, J., Gong, L., Zhou, J., Hao, Z., et al. (2025). Simulating classroom education with LLM-empowered agents. In *Proc. of NAACL 2025*, pages 10364–10379.

Zheng, L., Jiang, F., Gu, X., Li, Y., Wang, G., e Zhang, H. (2025). Teaching via LLM-enhanced simulations: Authenticity and barriers to suspension of disbelief. *The Internet and Higher Education*, 65:100990.